UJIAN TENGAH SEMESTER

NATURAL LANGUAGE PROCESSING

"UJI PERBANDINGAN HASIL ANALISIS SENTIMEN PADA DOKUMEN BERBAHASA INGGRIS DAN INDONESIA DENGAN METODE BAG OF WORDS (BOW) & TF-IDF"

NAMA **:** I Gede Dewangga Arya Putra

NIM **:** 2401020111

PROGRAM STUDI **:** Informatika

TOPIK : ANALISIS SENTIMEN

1. **LATAR BELAKANG**

   Perkembangan teknologi informasi mempermudah penggunanya untuk berinteraksi dengan apa yang tersaji di internet. Interaksi tersebut bisa saja berupa obrolan hingga memberi opini terhadap sesuatu. Opini masyarakat yang beredar dapat mempengaruhi citra atau persepsi terhadap suatu topik hingga membentuk sentimen. Bagi pihak yang peduli dengan sentimen dari opini publik, ini adalah salah satu indikator yang bisa mereka gunakan untuk melakukan evaluasi maupun riset. Natural Language Processing (NLP) adalah salah satu cabang ilmu teknologi informasi yang dapat dimanfaatkan untuk membantu hal tersebut. Natural Language Processing (NLP) memliki cabang yakni Analisis Sentimen, yang sesuai namanya, diperuntukan pada identifikasi bentuk sentimen dari dokumen.

2. **METODELOGI**

   Data yang digunakan adalah sebagai berikut :

   - Data dari dokumen Sentimen Finansial dalam bahasa Inggris bersumber dari Kaggle
   - Data dari dokumen Sentimen Sepakbola Indonesia di era Shin Tae Yong dalam bahasa Indonesia bersumber dari Kaggle

   Metode yang digunakan dalam project ini di antaranya:

   - Text Preprocessing : Cleaning, Tokenization, Stopword Removal, Stemming. Library yang digunakan : nltk, Sastrawi
   - Feature Extraction : menggunakan Bag of Words (BoW) dan TF-IDF. Hasilnya akan divisualisasikan dengan WordCloud, distribusi frekuensi token, plot TF-IDF

3. **HASIL EKSPERIMEN**

   3.1. Dokumen Sentimen FInansial (EN)

	Sentence	Sentiment	text	label
0	The GeoSolutions technology will leverage Bene...	positive	The GeoSolutions technology will leverage Bene...	positive
1	$ESI on lows, down $1.50 to $2.50 BK a real po...	negative	$ESI on lows, down $1.50 to $2.50 BK a real po...	negative
2	For the last quarter of 2010 , Componenta 's n...	positive	For the last quarter of 2010 , Componenta 's n...	positive
3	According to the Finnish-Russian Chamber of Co...	neutral	According to the Finnish-Russian Chamber of Co...	neutral
4	The Swedish buyout firm has sold its remaining...	neutral	The Swedish buyout firm has sold its remaining...	neutral

Gambar 1. Dataset yang digunakan

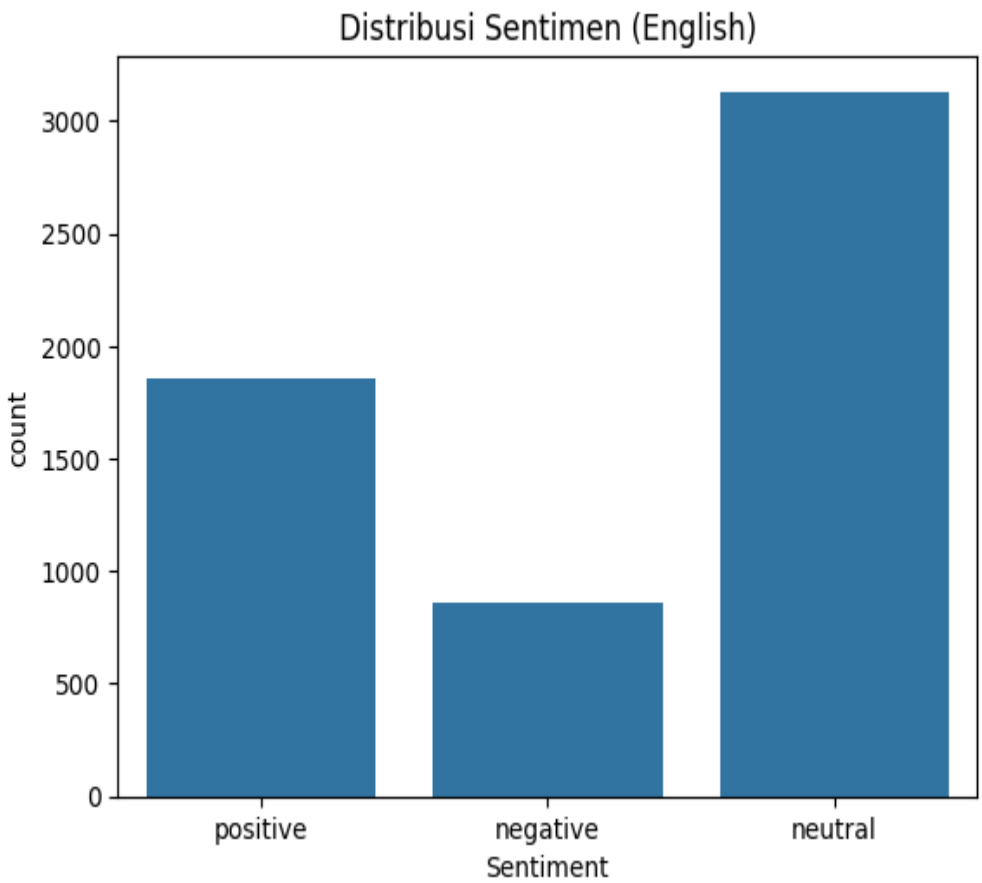

Gambar 2. Distribusi Sentimen Dataset

```
Akurasi EN BoW:  0.7142857142857143
              precision    recall  f1-score   support

    negative       0.44      0.37      0.40       175
     neutral       0.76      0.83      0.80       622
    positive       0.74      0.68      0.71       372

    accuracy                           0.71      1169
   macro avg       0.65      0.63      0.63      1169
weighted avg       0.71      0.71      0.71      1169
```

Gambar 3. Akurasi Bag of Words

```
Akurasi EN TF-IDF:  0.6706586826347305
              precision    recall  f1-score   support

    negative       0.80      0.05      0.09       175
     neutral       0.65      0.97      0.78       622
    positive       0.74      0.46      0.56       372

    accuracy                           0.67      1169
   macro avg       0.73      0.49      0.48      1169
weighted avg       0.70      0.67      0.61      1169
```

Gambar 4. Akurasi TF-IDF

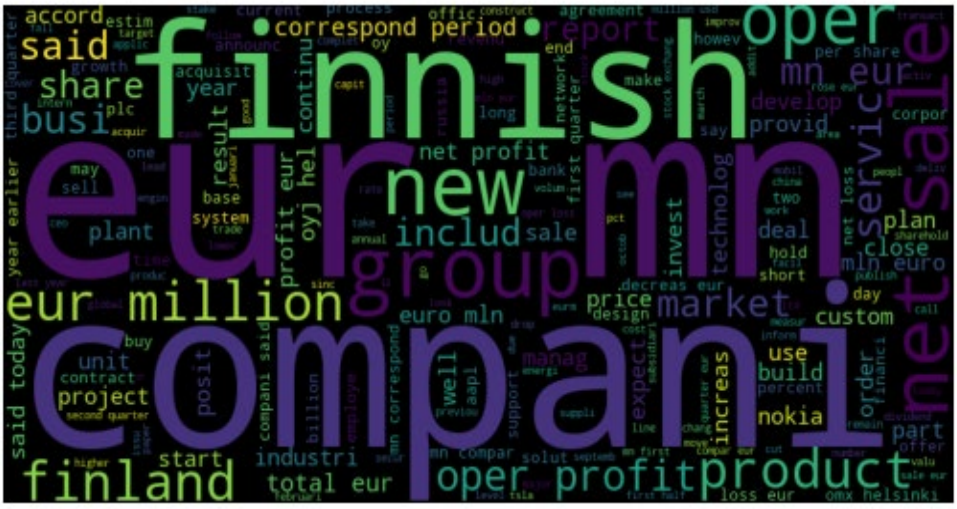
finnish
eur
mn
company
new
group
eur million
finland
said
share
busi
oper
sale
net sale
net profit
correspond period
report
product
profit
market
price
euro mln
plant
system
base
unit
project
contract
start
industri
total eur
oper
nokia
build
use
custom
deal
plan
close
mln euro
develop
provid
mn eur
service
technolog
invest
increas
expect
manag
well
posit
profit eur
oyj hel
result
year
acquisit
continu
accord
estim
said today
buy
may
sell
one
plc
growth
third quarter
earlier
year earlier
decreas eur
design
day
short
two
bank
first quarter
network
russia
long
make
per share
corpor
loss eur
omx helsinki
mn compar
solut
support
aapi
company said
billion
correspond
second quarter
higher
offer
part
order
financi
percent
remain
inform
call
publish
sharehold
work
pct
take
annual
trade
volum
volatil
china
people
delay
loss
net loss
rose eur
sale eur
valu
offer
remain
support
line
change
quarter
compar
eur
first half
september
on first
february
level tsla
supplier
employe
price
sinc
year earlier
last year
broke
ceo
time
lead
engin
trade
pct
take
annual

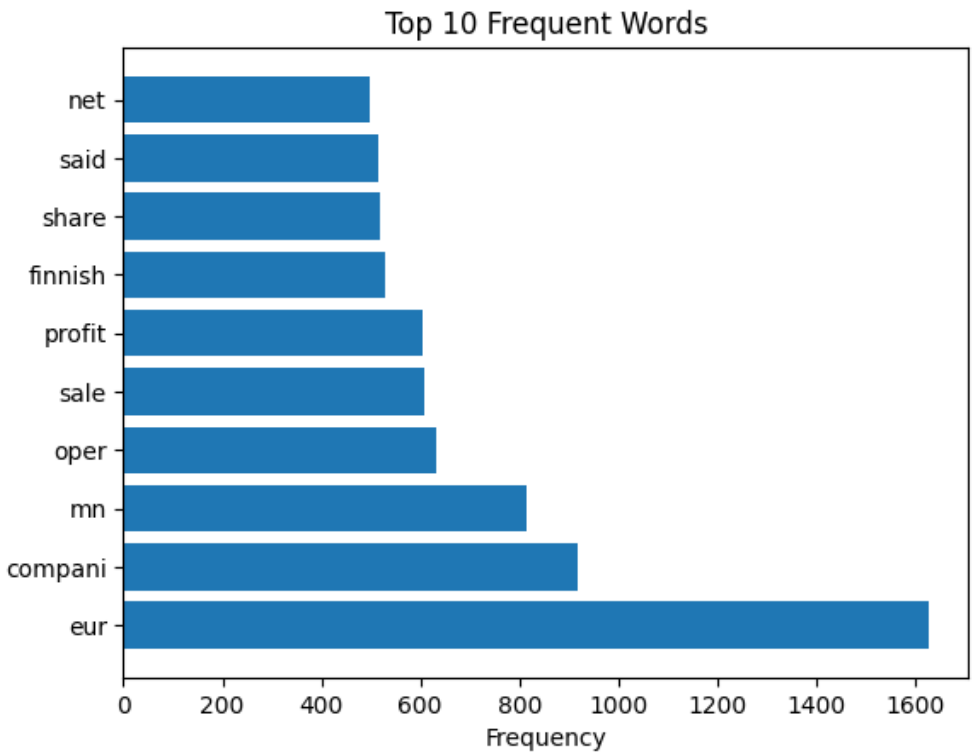

Gambar 7. Distribusi frekuensi Token

3.2. Dokumen Sentimen Sepakbola Indonesia di era Shin Tae Yong (ID)

	komentar	label	text
0	<username> Simulasi indonesia kembali dijajah ...	negatif	<username> Simulasi indonesia kembali dijajah ...
1	<username> <username> <username> keturunan lai...	negatif	<username> <username> <username> keturunan lai...
2	<username> <username> uda botak keturunan penj...	negatif	<username> <username> uda botak keturunan penj...
3	<username> <username> <username> Belum tentu, ...	negatif	<username> <username> <username> Belum tentu, ...
4	<username> <username> <username> Lu nya aja yg...	negatif	<username> <username> <username> Lu nya aja yg...

Gambar 1. Dataset yang digunakan

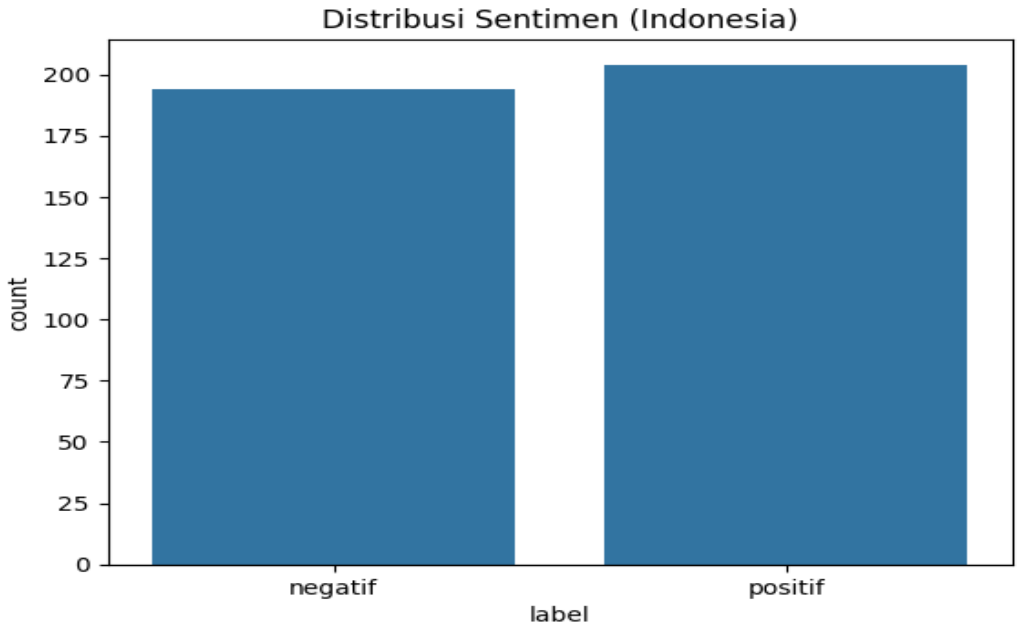

Gambar 2. Distribusi Sentimen Dataset

```
Akurasi id BoW:  0.7375
              precision    recall  f1-score   support

     negatif       0.90      0.59      0.71        44
     positif       0.65      0.92      0.76        36

    accuracy                           0.74        80
   macro avg       0.77      0.75      0.74        80
weighted avg       0.78      0.74      0.73        80

Akurasi ID TF-IDF:  0.725
              precision    recall  f1-score   support

     negatif       0.92      0.55      0.69        44
     positif       0.63      0.94      0.76        36

    accuracy                           0.72        80
   macro avg       0.78      0.74      0.72        80
weighted avg       0.79      0.72      0.72        80
```

Gambar 3. Akurasi BoW (atas) & Akurasi TF-IDF (bawah)

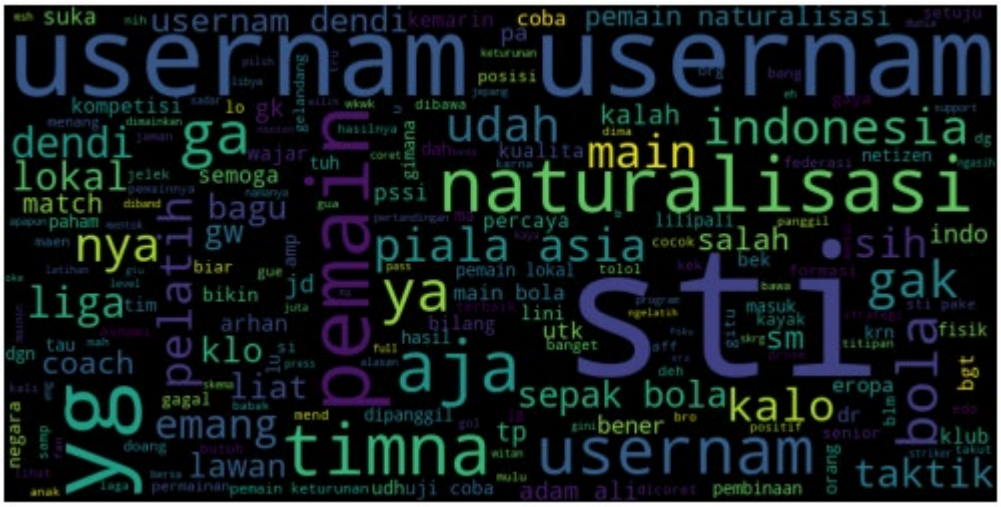

Gambar 4. WordCloud

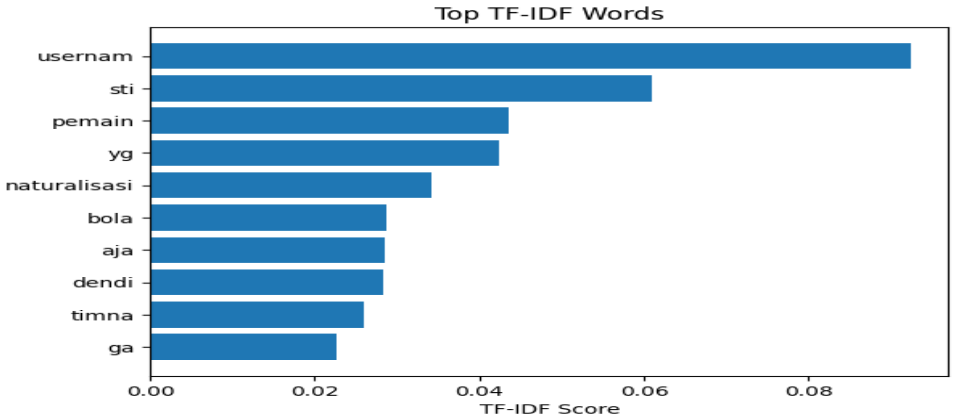

Gambar 5. Plor TF-IDF

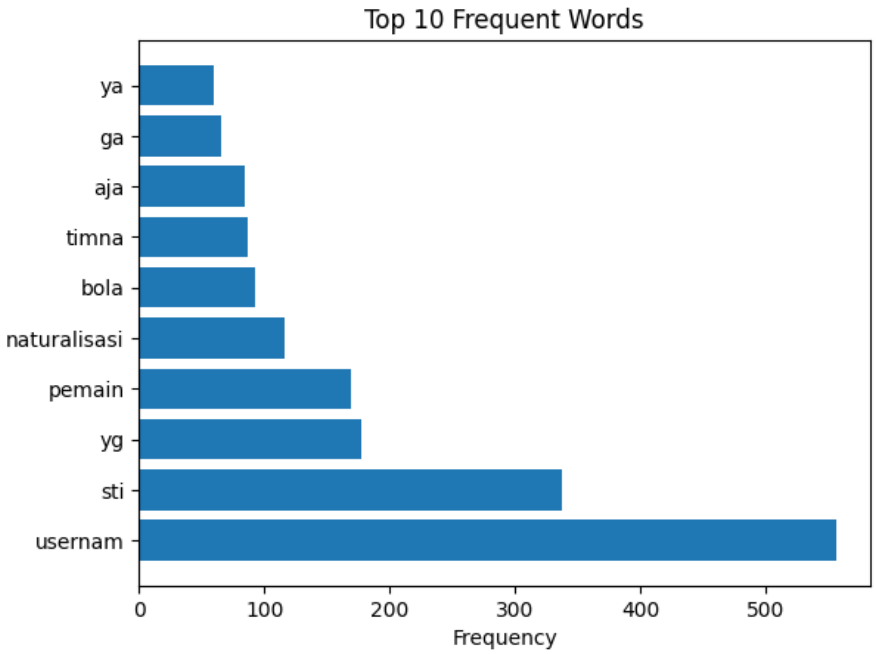

Gambar 6. Distrubusi Frekuensi Token

4. ANALISIS PERBANDINGAN METODE

Berikut ditampilkan confusion matrix dari masing-masing dataset

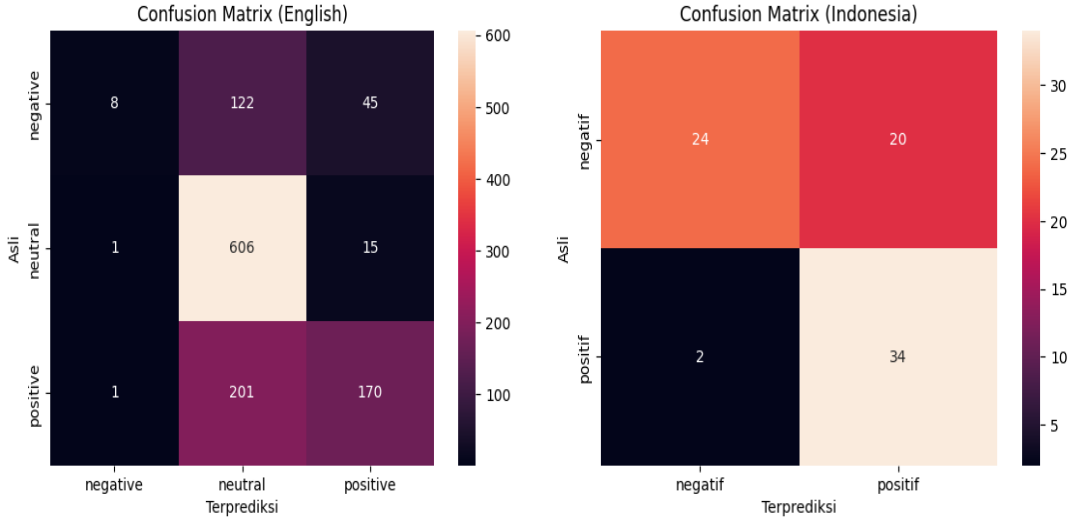

Terlihat jelas pada matriks bahasa Inggris memiliki kecenderungan atau bias pada label 'netral', menandakan model cukup baik dalam mengklasifikasikan label netral. Hanya saja, hal ini sangat timpang dengan hasil klasifikasi label positif dan label negatif. Berbeda halnya dengan matriks bahasa Indonesia. Meski terlihat bahwa ada kecenderungan atau bias ke label positif, tapi, jumlahnya tidaklah sangat jauh.

Lebih lanjut lagi, berikut hasil perbandingan metode BoW & TF-IDF

```
=== PERBANDINGAN ===
English BoW          : 0.7142857142857143
English TF-IDF       : 0.6706586826347305
Indonesia BoW        : 0.7375
Indonesia TF-IDF     : 0.725
```

Mengacu pada hal ini, kita bisa lihat bahwa metode BoW memiliki akurasi yang lebih baik dibanding TF-IDF di kedua dataset. Hal tersebut bisa jadi menandakan bahwa distribusi kata masih bisa direpresentasikan dengan baik oleh frekuensi sederhana atau bahkan TF-IDF justru mengurangi boobot kata tertentu yang sebenarnya penting dalam klasifikasi.

Selain itu, dataset yang digunakan memiliki pengaruh dalam pengujian metode ini. Performa uji dataset bahasa Indonesia jauh lebih baik dibandingkan dengan dataset bahasa Inggris. Ini bisa jadi menandakan bahwa dataset bahasa Inggris terlalu ditopang dengan label netral, sehingga mempengaruhi penilaian klasifikasi. Atau dataset bahasa Indonesia memiliki variasi kata yang sedikit dan efektif dalam penilaian klasifikasi.

5. KESIMPULAN

- Metode BoW memiliki hasil yang lebih baik daripada metode TF-IDF pada kasus ini
- Dataset bahasa Indonesia memiliki hasil yang lebih baik daripada dataset bahasa Inggris yang cenderung bias ke label netral, menandakan bahwa dataset juga memiliki pengaruh pada penilaian.

6. REFERENSI

[1] F. Ramadhan, "Analisis Sentimen Timnas Sepakbola di Era STY," 2024. [Online]. Available: https://www.kaggle.com/datasets/pajarbebek/analisis-sentimen-timnas-sepakbola-di-era-sty. [Accessed 16 April 2026].

[2] sbhatti, "Financial Sentiment Analysis," 2022. [Online]. Available: https://www.kaggle.com/datasets/sbhatti/financial-sentiment-analysis. [Accessed 16 April 2026].